Champs de Markov en Vision par Ordinateur

0 : Quelques Points avant Commencer : Contacts.

- Florent.Lafarge@inria.fr.
- www-sop.inria.fr/ariana/personnel/Florent.Lafarge
- Vous trouverez là l'original de ce document.

0 : Quelques Points avant Commencer : Vous.

- N'ayez pas peur :
  - *De questionner - la façon meilleure d'apprendre.*
  - *De demander que je répète ou explique quelque chose.*
  - *De me dire si le niveau est trop simple ou trop compliqué.*
- Envoyez-moi un email si vous avez des questions après le cours.

Buts.

- Définitions : qu'est-ce que sont les champs de Markov ?
- Exemples : comment sont-ils utilisés pour la compréhension d'images ?
- Algorithmes : comment peut-on extraire l'information désirée des modèles ?

Quelques elements simples d'une image

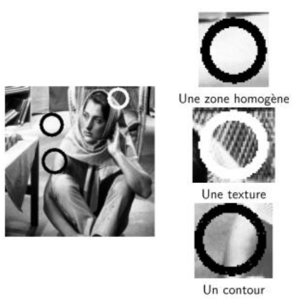

Notion de pixel

Définition : Un pixel est l'unité indivisible permettant de coder l'information relative à la luminosité en une certaine position

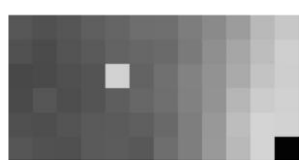

- les pixels sont généralement carrés
- pixel vient de « picture element »
- La taille du pixel

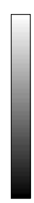

En niveau de gris

image numérique

Une image est un tableau de pixels : si le nombre de lignes vaut nl et le nombre de colonnes nc :

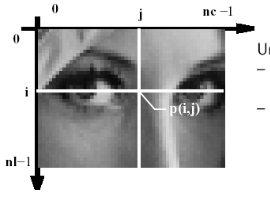

Un pixel est donc composé :
- de coordonnées (i, j) permettant de le situer,
- d'une valeur $v = p(i, j)$ représentant sa couleur .

image numérique

On peut voir l'image comme une fonction u et donc une surface.

$$u : \begin{array}{ccc} I \times J & \to & V \\ (i,j) & \to & p(i,j) \end{array}$$

"A un point on associe une valeur d'intensité"

En discret

$$\begin{array}{ll} I = \{0, \ldots, nl-1\} & \text{et, par exemple :} \\ J = \{0, \ldots, nc-1\} & V = \{0, \ldots, 255\} \end{array}$$

En continu

$$\begin{array}{ll} I = [0, l] & \text{et :} \\ J = [0, L] & V = [0, 1] \end{array}$$

L'avantage d'une telle représentation continue vient de la possibilité de dériver...

Formulation classique d'un problème en image

Entrée : une (ou plusieurs) image(s) où à chaque site est associé une intensité

Sortie : un ensemble d'étiquettes

Images : Deconvolution.

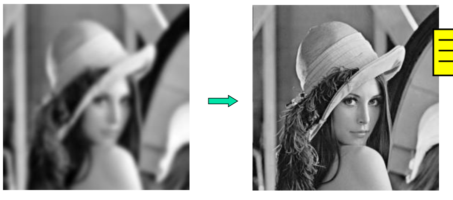

Images : Débruitage.

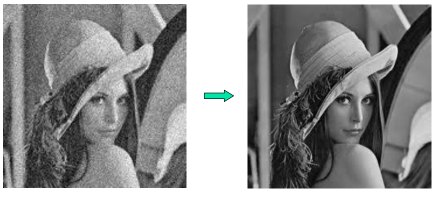

Images : Segmentation.

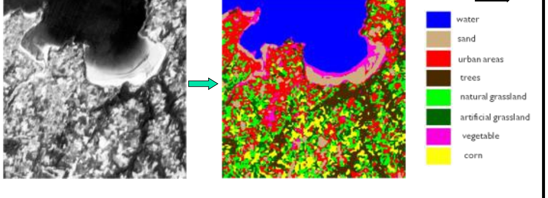

Images : Segmentation.

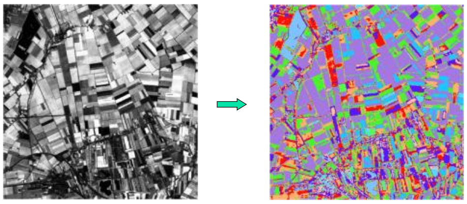

Images : estimation de mouvement.

Images : extraction de réseaux.

Images : extraction de réseaux.

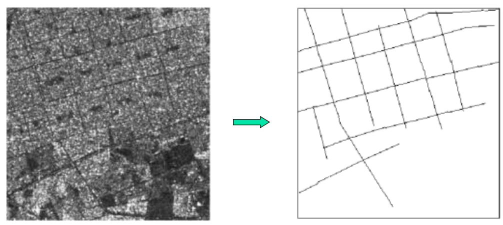

Images : extraction de réseaux.

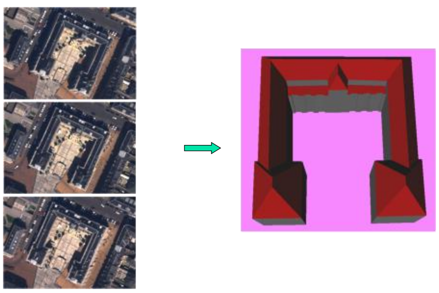

Part I : Définitions

problème inverse en image

soient: y, l'observation
x, l'etiquette

on veut retrouver x à partir des informations contenues dans y

la modélisation bayésienne

soient: y, l'observation
x, l'etiquette

On cherche don[illegible]chant y :

$$\Pr(X = x \;/\; Y = y) = \frac{\Pr(Y = y \;/\; X = x) \,.\, \Pr(X = x)}{\Pr(Y = y)}$$ Loi de Bayes

$$\underbrace{\Pr(X = x \;/\; Y = y)}_{\text{probabilité a posteriori de } x} \propto \underbrace{\Pr(Y = y \;/\; X = x)}_{\text{formation des observations}} \,.\, \underbrace{\Pr(X = x)}_{\text{a priori}}$$

la modélisation bayésienne

- La probabilité de l'image sachant la scène (la formation de l'image). Souvent un modèle physique. Appelée la vraisemblance.
- La probabilité de la scène avant d'avoir vu l'image. Appelée la probabilité a priori.
- On doit construire des modèles pour tous les deux.

la modélisation bayésienne

on cherche la configuration d'objets x qui maximise la probabilité P(X=x /Y=y)

→ **estimateur MAP :** $\hat{x} = \arg\max_{x \in \Omega} \mathbf{Pr}(X = x \;/\; Y = y)$

Probabilités sur ces espaces.

- L'espace d'images est énorme juste pour une image de 256*256 pixels
- Les probabilités sont fonction de 65536 variables dépendantes : les valeurs des pixels. Donc, il faut simplifier.

Simplification de la probabilité.

- Les probabilités se simplifient quand quelques variables sont indépendantes les unes des autres.
- Les champs de Markov sont une possibilité (mais pas la seule) pour définir des probabilités simplifiées mais encore utiles.

Exemple : Indépendance.

- Si la scène est décrite par une fonction sur D, la probabilité peut se factoriser sur les pixels s de l'ensemble des sites de l'image S :

$$\Pr(X|Y) = \prod_{p \in D} \Pr(X_p|Y_p)$$

- Dans ce cas, on peut traiter chaque pixel séparément (problème à une dimension).

Champs de Markov (MRFs).

$V = \{V(s)/s \in S\}$ *est un système de voisinage si*

- $s \notin V(s)$
- $s \in V(t) \iff t \in V(s)$

De plus, on appelle **clique**, *un sous-ensemble c de S dont les sites sont voisins deux à deux. On note C, l'ensemble de toutes les cliques asociées à* (S, V).

Champs de Markov (MRFs).

Soit $X = (X_s)_{s \in S}$ *un champ aléatoire associé à l'espace probabilisé complet* $(\Omega, \mathcal{F}, P)$.
X *est un* **champ de Markov** *relativement au système de voisinage V si*

$$\forall x \in \Omega, \forall s \in S, P(X_s = x_s | X_r = x_r, r \in S - \{s\}) = P(X_s = x_s | X_r = x_r, r \in V(s))$$

Théorème de Hammersley-Clifford.

Le théorème suivant permet de caractériser la distribution d'un tel champ : c'est le théorème d'Hammersley-Clifford.

Théorème 2 (Hammersley-Clifford)
Soit X un champ de Markov associé à l'espace probabilisé $(\Omega, \mathcal{F}, P)$, *et tel que* $\forall x \in \Omega, P(X = x) > 0$.
Alors, la distribution $P(X)$ *de ce champ est une distribution de Gibbs :*

$$P(X) = \frac{\exp -U(X)}{Z}$$

où $U(X) = \sum_{c \in C} V_c(X_s, s \in c)$ *et* $Z = \sum_{X \in \Omega} \exp -U(X)$

Distribution de Gibbs B.

- U est appelé l'énergie. Z est appelé le fonction de partition.
- Pour une distribution de Gibbs, l'estimée MAP prend une forme simple:

$$x^* = \arg\min U(x)$$

- Cette forme on appèle minimisation d'énergie.

Quel model pour l'a priori ?

- Étiquette binaire: Ising
- Étiquette non-binaire: Potts $U_p(x_s, x_{s'}) = \begin{cases} 0 & si\ x_s = x_{s'} \\ \beta & \text{sinon} \end{cases}$
- ou créer le modèle a priori que l'on veut !

exemple 1

Intensité = {*rouge clair, rouge foncé, bleu clair, bleu foncé*} (y)

Etiquette = {*blanc, noir*} (x)

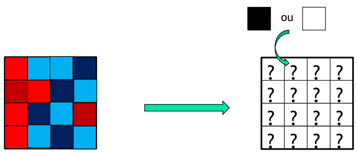

image d'entrée

Image de sortie

Intensité = {*rouge clair, rouge foncé, bleu clair, bleu foncé*} (y)
Etiquette = {*blanc, noir*} (x)

exemple 1

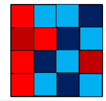

image d'entrée

Modèle énergétique : $U(x) = U_{data}(x) + U_{prior}(x)$

$$= \sum_{s \in S} U_d(x_s) + \sum_{s \in S} \sum_{s' \in V(s)} U_p(x_s, x_{s'})$$

- $U_d(x_s) = \begin{cases} 0 & si\,(x_s = 'blanc' \cap y_s = 'rouge') \cup (x_s = 'noir' \cap y_s = 'bleu') \\ 1 & \sin on \end{cases}$
- $U_p(x_s, x_{s'}) = \begin{cases} 0 & si\ x_s = x_{s'} \\ \beta & \sin on \end{cases}$
- Voisinage : 4-connexité

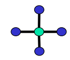

Intensité = {*rouge clair, rouge foncé, bleu clair, bleu foncé*} (y)
Etiquette = {*blanc, noir*} (x)

exemple 1

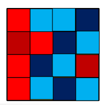

image d'entrée

Questions:

1-quelle est la configuration x qui minimise la vraisemblance $U_{data}(x)$?

2-quelle est la configuration x qui minimise l'a priori $U_{prior}(x)$?

3-quelle est l'énergie des trois configurations suivantes ?
Quelle est la meilleure configuration ?

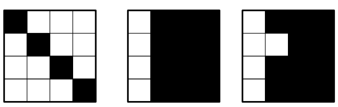

4-meme questions mais avec un voisinage en 8-connexité

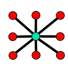

---

exemple 2

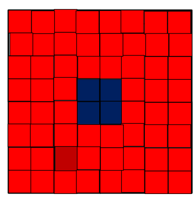

Question:
Pour quelles valeurs de β, la solution optimale est-elle la suivante en 4-connexité ?